모델기술서

2026 AI 농산물 가격예측 온라인 해커톤 본선

팀 정보

IMPACT Lab · 작성자 IMPACT LAB · 작성일 2026-11-08 · 문서 버전 1.2

최종 제출 묶음은 v11_zero_linux 이며 내부 모델 버전은 hackathon-ensemble-v11-zero 입니다. 이 보고서는 아래 세 최고 기록 제출본을 설명합니다. 공통 학습 코드·데이터·실행 환경은 한 번만 기술하고, 트랙별 목표·모델·후처리 차이는 각 규칙 표에서 구분합니다.

제출 ID 별 설명 연결: 세 트랙은 아래 표와 「품목·트랙별 규칙」에 대응합니다. 공통 입력·전처리·학습 경계·재현 절차는 이어지는 공통 절에 해당합니다. 점수는 2026-11-08 포털에 표시된 최고 기록입니다.

모델	제출 ID · 포털 MAPE	어떤 모델인가요
10 일 예측	efb84521-3be6-400d-a7cd-3bafe184d8b8 9.1231%	hackathon-ensemble-v11-zero 10 일 예측(short). 품목별 고정 규칙의 ExtraTrees/HGB 풀링 은행. 입력: aT 일별가격, 정산물량, 산지·가락·전국 정산 가격, 기상, 공휴일 달력
2 순 후	8a444125-5fa9-4f0b-a629-0798d3ee5e70 11.4627%	같은 묶음의 2 순 후(long1). 2 순 후 10 일 블록 평균가격 예측. 입력 동일
3 순 후	89502728-5402-4953-bc33-87d0f19ca58e 10.8410%	같은 묶음의 3 순 후(long2). 3 순 후 10 일 블록 평균가격 예측. 입력 동일

어떤 정보를 보고 가격을 예측하나요

가격 자료. 운영진이 배포한 aT 공식 일별 가격(가격_일별_2020_2024.csv, 가격_일별_2025.csv)을 그대로 사용합니다. 단위는 자료의 unit 열(배추 10kg, 무 20kg, 양파 1kg, 깐마늘 1kg, 건고추 600g) 그대로이며 환산하지 않습니다. 학습 기간은 2020-01-02~2024-12-31, 추론에서는 각 기준일보다 엄격히 이전 관측만 읽습니다.

보조 자료. 전국 도매시장 정산물량, 농협 산지공판장 상등급 가격·반입량, 가락·전국 도매시장 정산 가격·물량, 기상청 ASOS 일별 관측, 법정 공휴일 달력을 사용합니다. 모두 운영진 배포본이며 파일 위치·용도는 뒤의 자료 표에 기재했습니다. 최종 패키지는 별도의 외부 예보·보고서·사전학습 모델을 사용하지 않습니다.

입력 특성. D 직전 마지막 가격 L, EWMA 기준 수준(e20·e50), 가격 이동평균·수익률·변동성(vol30·vol90), 연중 일자 sin/cos, 과거 같은 시기의 평균 로그 변화(seas)와 중앙값(seas_med), 전년 동기 비율, 물량·산지·가락·전국 정산 가격과 물량 비율, 14·30 일 기온·강수 및 서리·폭염·호우 특성을 사용합니다. 예측 거리·구간 길이·요일·월, 블록 모멘텀과 전년 대비 이상치도 포함됩니다. 최근 창·전년 창 등 관측값을 참조하는 모든 구간은 D 이전으로 제한하고, 미래 날짜의 달력 정보는 관측값과 구분합니다.

입력에서 예측값까지 어떻게 처리하나요

전처리. 가격의 0 이하·결측을 제외하고 날짜×품목 표를 구성하며, 구간 평균은 관측값으로 계산하고 가격을 보간하지 않습니다. ExtraTrees 앞의 SimpleImputer(strategy="median")는 학습 행으로 적합한 중앙값을 저장해 추론에 적용합니다. HGB 는 이 imputer 없이 결측값을 처리합니다. 학습 유효값이 2 개 미만인 특성 열은 0 으로 바꾸고 해당 열 목록을 예측에도 적용합니다. 별도의 표준화 변환은 없습니다.

모델. 5 품목의 표를 함께 사용해 ExtraTrees 와 HistGradientBoosting(HGB) 은행을 학습합니다. 기본 목표는 log(목표가격/L)에서 EWMA 기준 로그 비율을 뺀 값입니다. 학습 기준일 후보는 2020-07-01~2024-12-30 의 일별 격자이며, 유효 입력·정답과 은행별 컷오프 조건을 만족하는 행을 사용합니다. 은행 A 의 목표 종료일 상한은 2024-12-30, B 는 2024-12-31 입니다. ExtraTrees 의 트랙별 그루 수·특성 비율·최소 잎 표본 수와 HGB 설정은 config.json 에 기록했습니다. pooled_mw 는 absolute_error 손실에 sample_weight=exp(−y)=L/목표가격을 사용합니다(y 는 기준 수준 차감 전 로그 비율). 이는 가중 로그 오차 목적함수이며 직접적인 MAPE 최소화와 같다고 주장하지 않습니다.

품목·트랙별 규칙. 10 일: 배추 et 에 변동성 감쇠(lam=0.1)와 ewma50+0.5seas 앵커(w_max=0.25)를 적용합니다. 무는 et+block, et_mf3+block, et_hg_x3+block, pooled_mw+block, b1_coint, b1_coint 의 여섯 항을 동일 가중 로그 혼합합니다(b1_coint 총 비중 2/6). 여기에 감쇠(lam=0.75, block 앵커)와 배율 0.9813 을 적용합니다. 양파는 h1last_et_hg_e20_x3 에 1.0086 을 곱하므로 h=1 의 최종값도 1.0086×L 입니다. 2 순 후: 배추 pooled_mw+ewma+seas×0.9442, 무 et_mf3_e20_wx×0.9553, 양파 et|et+block|et+ewma+seas 혼합×0.9827 에 volshrink=0.25 를 적용합니다. 3 순 후: 배추 pooled_mw+ewma+seas×0.9261, 무 et_mf3_e20_wx+ewma50×0.9387, 양파 et_clip×0.9773 입니다. 세 트랙 모두 깐마늘·건고추는 last 를 사용합니다.

후처리. 로그 예측의 클립(±log 4), 가격 역변환, 고정 배율·앵커 혼합과 명절 배율을 코드 순서대로 적용합니다. 10 일 명절 오프셋은 명절·인접 공휴일·일요일로 구성한 휴장 구간 경계에서 셉니다. 설날 휴장 종료 후 1~5 일 배추×1.1365, 추석 휴장 시작 1 일 전 배추×1.2276, 3 일 전·1 일 전 무×1.0985 입니다. 2 순 후는 설날 명칭이 있는 첫 공휴일이 포함된 순과 이후 두 순의 무×1.1159 를 적용합니다. 장기 목표는 공식 순 구간의 관측 가격 평균입니다. 최종 출력은 소수점 4 자리이며, 추론 중 추가 학습이나 잔차 피드백 가중 갱신은 없습니다.

모델링 선택의 연구 근거

품목 풀링과 상대 가격 목표. 다섯 품목의 사례를 공통 은행에 모으고 품목 정보를 특성으로 넣어 공통 반응과 품목별 차이를 함께 표현합니다. 이는 여러 시계열에서 하나의 예측 함수를 학습하는 Montero-Manso 와 Hyndman 의 글로벌 예측 관점[3]과 연결됩니다. 목표 log(Y/L)는 가격 단위와 수준 차이를 줄이고 비율 변화를 가법적으로 표현합니다. 로그 변환의 해석은 [9]의 3·5 장을 따르며, 역변환값을 자동으로 조건부 평균이라고 해석하지 않습니다.

트리 앙상블과 복잡도 제어. ExtraTrees 는 분할 특성과 임계값의 무작위화로 서로 다른 트리를 구성하는 방법입니다[1]. 본 구현의 특성 비율 0.3/0.5 와 최소 잎 표본 수는 분할 다양성과 국소 적합의 세밀함을 조절합니다. HGB 는 트리를 순차적으로 더하는 부스팅 계열[2]이며, 학습률 0.03, 최대 15 개 잎, 최소 잎 표본 수와 L2=2.0 을 통해 갱신 크기와 복잡도를 제한합니다. 정확한 트랙별 설정은 config.json 과 학습 전략보고서에 기재합니다.

평가 손실과 학습 목표. de Myttenaere 등의 연구[4]는 가격 공간의 MAPE 와 역목표값 가중 절대오차의 관계를 설명합니다. pooled_mw 는 상대 목표 y=log(Y/L)에 대해 L/Y=exp(−y)를 가중치로 쓰지만 손실을 로그 공간에서 계산하므로 MAPE 를 고려한 대리 목적함수입니다. Gneiting[7]의 관점에 따라 평균·중앙값·비율오차 최적 예측을 구분하고 실제 평가는 가격 공간의 MAPE 로 수행합니다.

예측 결합과 단순 기준 수준. 트리 예측을 최근 가격·EWMA·과거 계절 변화와 결합하는 것은 한 예측 방식에 대한 의존을 줄이려는 구조이며 예측 결합 연구[5]와 연결됩니다. 로그 공간 평균은 가격 공간의 기하평균에 해당합니다. 마지막 가격 유지와 지수평활은 표준 기준 예측입니다[9, 5·8 장]. ewma50 의 50 은 50 일 창이 아니라 평활계수 0.50 을 뜻하며, 깐마늘·건고추에는 last 규칙을 사용합니다.

예측 거리와 달력 정보. 1~3 일·4~6 일·7~10 일 그룹은 거리별 반응을 구분하면서 각 그룹의 학습 표본을 공유합니다. Ben Taieb 와 Hyndman[6]은 다단계 예측에서 거리별 편향과 추정 분산의 차이를 논의합니다. 연중 sin/cos, 과거 계절 변화와 명절 규칙은 달력 효과를 표현하고, 과거 기상·반입량·시장 가격은 기준일의 시장 상태를 보완합니다[9, 7 장]. 특정 창과 그룹 경계는 제출 설정에 고정된 설계값입니다.

고정 후처리의 역할. 변동성 감쇠·앵커 혼합·클리핑은 급격한 외삽을 제한하고, 품목 배율과 명절 배율은 가격 수준 및 달력 구간을 조정합니다. [5]·[7]은 결합과 손실에 따른 예측값 해석의 근거이며, 개별 계수나 명절 구간을 도출하는 공식은 아닙니다. 본문은 문헌이 뒷받침하는 방법론과 config.json 의 수치 설정, 2022~2024 진단 결과를 구분해 설명합니다.

미래 정보가 들어가지 않도록 어떻게 막았나요

학습 경계. train.py 는 D.bundle(infer=False)와 Extras(train=True, infer=False)로 2020~2024 학습 자료를 읽고 가격 최대 날짜가 2024-12-31 이하인지 확인합니다. 각 은행은 목표 종료일이 컷오프를 넘는 행을 제외합니다. y3 중심 목표를 쓰는 경우에는 추가 하루를 제외합니다. A 는 2024-12-31 기준일에, B 는 이후 기준일에 적용합니다. 매니페스트의 cases·training.bank_cutoffs 에 이 대응이 기록되어 있습니다.

추론 경계. input/by_case/C01~C12 에는 사례 기준일 D 보다 앞선 관측 행만 들어 있고, predict.py 는 input-manifest.json 의 사례 ID 와 기준일을 확인해 해당 폴더를 선택합니다. C12 의 모든 관측 날짜는 2025-11-30 보다 앞섭니다. 특성 계산 또한 Daily.last(D)와 D 이전 최근·과거 연도 구간을 사용합니다. 파일별 관측기간·행 수·SHA-256 은 사례별 매니페스트에 기록했습니다. 공휴일 날짜는 관측값이 아닌 달력 입력입니다.

사례별 통계와 고정 규칙. EWMA·이동평균·변동성·비율은 각 기준일의 허용 입력으로 계산합니다. 계수 lam, w_max, 배율과 혼합비율은 config.json 에 고정되어 있습니다. state_space 는 고정 감쇠 $\text{plog}-=\text{lam}\times\text{vol30}^2\times h/10$ 및 앵커 가중치 $\text{w_max}\times h/10$ 을 적용하는 설정명이며, 적합된 Kalman 필터가 아닙니다. 최종 추론 코드에는 2025 자료로 모델을 추가 학습하거나 최근 잔차로 가중을 갱신하는 절차가 없습니다.

정정본·달력과 설명 범위. 운영진 배포 자료를 사용하며 사례별 관측 날짜를 절단합니다. 미래 명절 날짜는 공휴일 달력으로 사용합니다. 최종 2025 달력은 원본 20 행이며 2026 년 행을 추가하지 않았습니다. 학습·입력 경계와 고정 설정은 코드와 명세로 확인할 수 있습니다. 설정의 역사적 선택 과정에 관한 근거 범위와 검증의 한계는 학습 전략보고서의 「진단과 선택 이력의 범위」에 별도로 적었습니다.

2022 년부터 2024 년까지의 전진 검증

검증 구조. 기본 모델은 2020~2021 자료로 학습해 2022 년 기준일을 평가하고, 2020~2022 자료로 2023 년을, 2020~2023 자료로 2024 년을 평가합니다. 각 학습 목표는 전년도 말까지 종료되어야 하며, 평가 시 입력 관측은 해당 기준일보다 앞선 값만 사용합니다. 이는 시간 순서를 지키는 시계열 검증 원칙[9, 5 장]을 연도 단위 확장 창으로 구현한 것입니다. 폴드별 날짜·표본 격자·지표 해석은 학습 전략보고서에 명시합니다.

결과의 해석. 기본 은행은 평가 연도 이전 자료로 적합하지만 배율 계산과 조정 후 평가에는 같은 2022~2024 폴드가 사용됩니다. 따라서 조정 후 점수는 보정 진단으로 해석합니다. 고정 설정의 진단과 새로운 자료에 대한 독립 평가는 구분하며, 이 구분은 선택 편향을 다룬 Cawley 와 Talbot[8]의 논의와 일치합니다. 최종 제출 은행은 별도의 일별 학습 격자와 A/B 컷오프로 2020~2024 자료를 사용해 재학습합니다.

모델 실행 방법

운영진은 제출한 가중치로 예측을 다시 실행합니다. 이어서 학습 전략보고서의 방법으로 처음부터 학습합니다.

어떤 환경에서 실행하나요

실행 환경. Ubuntu 24.04.4(WSL2, Linux x86_64), Intel Core Ultra 7 265KF, CPython 3.14.8 일반 GIL 빌드, requirements.txt 의 지정 패키지, 4 스레드·CPU 환경입니다. 검증 실행은 네트워크를 차단한 상태에서 수행되었습니다. 이 최종 후보의 macOS·Windows 재학습은 확인하지 않았습니다.

라이브러리. model/requirements.txt 에 numpy==2.5.3, pandas==3.0.6, scikit-learn==1.9.1, scipy==1.18.1, joblib==1.6.0, threadpoolctl==3.7.0 을 고정했습니다. 환경 준비 명령은 python -m pip install -r model/requirements.txt 입니다. 패키지 설치를 마친 뒤 모델 실행 자체는 네트워크 없이 가능합니다.

어떻게 예측을 실행하나요

세 ZIP 을 같은 상위 폴더 아래 model/, training/, input/에 풉니다(모델.zip → model/, 전체 학습 데이터.zip → training/2020-2024/…, 입력 자료.zip → input/cases.json, input/by_case/…). 실행 안내는 model/REPRODUCE.md 에 있으며 다음 명령으로 예측합니다.

python model/script.py --output reproduced.csv

script.py 는 config.json 의 package_track(short / long1 / long2)으로 트랙을 정하고 input/cases.json 의 사례·기준일·목표 기간을 읽어 predict.py 를 실행합니다. 가중치는 model/weights.joblib, 규칙은 model/config.json, 출력은 --output 경로의 CSV(--audit 로 사례별 마지막 관측일·은행·방법 기록 JSON)입니다. 예측가격.xlsx 는 같은 값을 workbook.py 로 옮긴 것입니다. 새 기준일에는 그 기준일 이전 행만 담은 사례 폴더와 cases.json, input-manifest.json 을 같은 구조로 제공하면 같은 명령으로 예측합니다(기존 input/<연도>/ 구조도 지원).

세 모델을 직접 다시 실행해 보았나요

모델	실행 일시·환경	결과 파일 위치	원본 예측값과 비교
10 일 예측	2026-11-08 Ubuntu 24.04.4 / WSL2 CPython 3.14.8 4 스레드·네트워크 차단	model/reproducibility.json observed_verification · reproduced.csv(SHA-256 55e1375e…)	600 개 모두 일치 최대 차이 0 저장 가중치·새 Linux 재학습 모두 확인
2 순 후	2026-11-08 Ubuntu 24.04.4 / WSL2 CPython 3.14.8 4 스레드·네트워크 차단	reproduced.csv(SHA-256 a0293d43…)	60 개 모두 일치 최대 차이 0 저장 가중치·새 Linux 재학습 모두 확인
3 순 후	2026-11-08 Ubuntu 24.04.4 / WSL2 CPython 3.14.8 4 스레드·네트워크 차단	reproduced.csv(SHA-256 dac8c8be…)	60 개 모두 일치 최대 차이 0 저장 가중치·새 Linux 재학습 모두 확인

재현 범위. 제출 패키지의 reproducibility.json/observed_verification 에는 저장 가중치 추론과 새 Linux 재학습이 각각 제출 엑셀의 600 개·60 개·60 개 예측값과 모두 일치하고 최대 차이가 0 인 것으로 기록되어 있습니다. 같은 검증 환경의 반복 재학습에서도 동일한 가중치가 생성되었습니다. 이 결과를 다른 운영체제·CPU·스레드 수 전체에 대한 동일성 보장으로 해석하지 않습니다.

실행할 때 주의할 점이 있나요

실행 범위와 주의점. CPU 만 사용하며 학습·추론 중 외부 다운로드는 없습니다. 실행 전 requirements.txt 의 고정 패키지를 준비합니다. script.py/predict.py 는 --output·--audit 경로, train.py 는 --out 경로에 파일을 씁니다. 실행 시간·메모리는 장치와 실행 조건에 따라 달라집니다. 다른 scikit-learn 버전에서는 가중치 로드에 문제가 생길 수 있으며, 다른 플랫폼의 재학습은 일부 예측값이 달라질 수 있습니다. 확인된 재현 범위는 위 Linux 환경입니다.

제출 명세와 연결

파일 해시·실행 환경·확인 결과는 각 모델 ZIP 의 reproducibility.json, 실행 명령은 REPRODUCE.md, 사례별 입력 대응은 입력 ZIP 의 input-manifest.json 을 참조합니다. 전체 학습 데이터 ZIP 은 세 트랙 공통이며 SHA-256 은 0bac3ca6…입니다.

트랙별 최종 제출 파일은 모델.zip, 전체 학습 데이터.zip, 입력 자료.zip, 예측가격.xlsx 입니다. 이 보고서의 제출 ID 표와 각 트랙의 설명은 이 네 파일로 이루어진 v11_zero_linux 원본에 대응합니다.

보고서 확인 범위: 세 제출 ID·트랙·기록 점수, 최종 패키지의 파일 명세·설정·실행 명령, 기록된 Linux 재현 결과를 서로 대조했습니다. 재현 결과는 확인한 환경에 한정해 기재했습니다.

외부자료 사용 내역

출처와 판본. 공식 원본의 출처·판본 설명은 학습 ZIP 의 README·TRAINING_MANIFEST·DATA_DICTIONARY 와 입력 ZIP 의 source_metadata 에 보존했습니다. 사례별 잘린 입력의 행 수·관측기간·해시는 input-manifest.json 을 참조합니다. 아래의 원본 해시는 잘린 사례별 파일 해시와 구분합니다.

자료명	공식 출처·파일 위치	공표 시점·근거	사용 항목·기간	학습·추론 용도	미확인 사항
aT 공식 일별 가격 가격_일별_2020_2024.csv / 가격_일별_2025.csv (예측 목표와 같은 가격)	**운영진 배포 학습·입력 자료.** 전체 학습 데이터.zip/2020-2024/가격_일별_2020_2024.csv (SHA-256 b6ee8aa5…), 입력 자료.zip 2025 파일(원본 SHA-256 4796d7c7…)	운영진 배포본의 TRAINING_MANIFEST·DATA_DICTIONARY 기재. 별도 공표 시점 확인은 하지 않음	배추·무·양파·깐마늘·건고추 5 품목. 학습 2020-01-02~2024-12-31, 추론은 각 기준일 D 이전 행만	학습(은행 학습·검증) 및 추론(마지막 가격 L, EWMA 기준 수준, 이동평균·변동성·계절 특징). 12 개 기준일 2024-12-31~2025-11-30	없음
전국 도매시장 정산물량 물량_일별_2020_2024.csv / 물량_일별_2025.csv	운영진 배포 Supplementary. SHA-256 c07f1abc…(2020~2024) / 17a06f91…(2025), 출처 at.agromarket.kr/domeinfo/statsDay.do	운영진 배포본 매니페스트 기재(정산 집계, 공표·수집일은 관측일과 다를 수 있음)	5 품목 kg. 학습 2020~2024, 추론은 D 이전 행만	학습·추론 공통. 물량 비율 특징(v7_30, v7_ly, v30_ly, v14_ly 등)	없음
기상청 ASOS 일별 관측 weather_daily.csv (2020~2024 / 2025)	운영진 배포 Supplementary/날씨와공휴일_*. SHA-256 13f4e8a8…(2020~2024) / fa663b5b…(2025 원본), 출처 data.go.kr/data/15059093	운영진 배포본 DATA_DICTIONARY 기재(관측일 필터만 적용)	전국 관측소 평균 기온(avgTa·minTa·maxTa)·강수량(sumRn)과 일부 산지 관측소. 학습 2020-01-01~2024-12-31, 추론은 tm < D	학습·추론 공통. 14·30 일 기온·강수 창, 서리·폭염·호우 일수(ta14, tmin14, rn14, rn30, n_frost14, n_heat14, n_heavy14)	없음

자료명	공식 출처·파일 위치	공표 시점·근거	사용 항목·기간	학습·추론 용도	미확인 사항
공휴일 달력 public_holidays.csv (2020~2024 92 행 / 2025 20 행)	운영진 배포 Supplementary/ 날씨와공휴일_*. SHA-256 6164030a…(2020~2024) / 17c9d363…(2025 원본), 출처 data.go.kr/data/15012690	법정 공휴일 달력(관측값이 아닌 사전 확정 달력 입력)	설날·추석 날짜만 사용. 학습 2020~2024 폴드 잔차 계산, 추론 2025 명절 전후 배율 적용	명절 보정 규칙(config.json holiday_short / holiday_block). 기준일 이후의 명절 날짜도 달력으로 사용	최종 입력 ZIP 의 사례별 2025 달력은 각각 20 행이며 운영진 원본 SHA-256 17c9d363…과 일치합니다. 추가된 2026 년 공휴일 행은 없습니다.
농협 산지공판장 가격·반입량 origin_daily.csv / origin_daily_2025_grade12.csv	운영진 배포 Supplementary/ 시장별_경락정보_*. SHA-256 a8c3a9f2…(2020~2024) / 7c612451…(2025 원본), 출처 nongnet.or.kr 공판장 정보	운영진 배포본 매니페스트 기재	상등급 원/kg 가격·반입량 t. 학습 2020~2024, 추론은 D 이전 행만(품목 단위 환산 UNIT_KG 적용)	학습·추론 공통. 산지 가격·반입량 비율 특징(op7_30, op7_L, oa7_30, oa7_ly)	없음
가락시장 정산 가격·물량 garak_daily.csv / settlement_daily_2025.csv(market_scope=garak)	운영진 배포 Supplementary/ 시장별_경락정보_*. SHA-256 ae204489…(2020~2024) / 47e4682a…(2025 원본), 출처 at.agromarket.kr/domeinfo/statsDay.do	운영진 배포본 매니페스트 기재(정산 집계)	전체 등급 정산금액÷정산 물량 원/kg, 정산물량 kg. 학습 2020~2024, 추론은 D 이전 행만	학습·추론 공통. 가락 가격·물량 비율 특징(gp3_7, gp7_L, gv7_30, gv7_ly)	없음
전국 도매시장 정산 가격·물량 wholesale_daily.csv / settlement_daily_2025.csv(market_scope=national_wholesale)	운영진 배포 Supplementary/ 시장별_경락정보_*. SHA-256 4a5dfd83…(2020~2024), 출처 at.agromarket.kr/domeinfo/statsDay.do	운영진 배포본 매니페스트 기재(정산 집계)	전국 정산 원/kg·kg. 학습 2020~2024, 추론은 D 이전 행만	학습·추론 공통. 전국 정산 가격·물량 특징(np3_7, np7_30, nv7_30, nv7_ly, nup7)	없음

참고문헌

본문의 [1]~[9]는 아래 문헌에 대응합니다. 논문 8 편과 예측 방법론 교재 1 권을 인용하며, 링크는 출판사 DOI 또는 저자·학술지 공개 원문으로 연결됩니다.

[1] Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. Machine Learning, 63, 3–42.
DOI: 10.1007/s10994-006-6226-1

[2] Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. The Annals of Statistics, 29(5), 1189–1232.
DOI: 10.1214/aos/1013203451

[3] Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. International Journal of Forecasting, 37(4), 1632–1653.
저자 공개본: arXiv:2008.00444

[4] de Myttenaere, A., Golden, B., Le Grand, B., & Rossi, F. (2016). Mean Absolute Percentage Error for regression models. Neurocomputing, 192, 38–48.
저자 공개본: arXiv:1605.02541

[5] Wang, X., Hyndman, R. J., Li, F., & Kang, Y. (2023). Forecast combinations: An over 50-year review. International Journal of Forecasting, 39(4), 1518–1547.
DOI: 10.1016/j.ijforecast.2022.11.005 · 저자 공개본

[6] Ben Taieb, S., & Hyndman, R. J. (2014). Boosting multi-step autoregressive forecasts. Proceedings of the 31st International Conference on Machine Learning, PMLR 32(1), 109–117.
논문 및 원문: proceedings.mlr.press/v32/taieb14.html

[7] Gneiting, T. (2011). Making and Evaluating Point Forecasts. Journal of the American Statistical Association, 106(494), 746–762.
DOI: 10.1198/jasa.2011.r10138 · 저자 공개본

[8] Cawley, G. C., & Talbot, N. L. C. (2010). On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. Journal of Machine Learning Research, 11, 2079–2107.
논문 및 원문: jmlr.org/papers/v11/cawley10a.html

[9] Hyndman, R. J., & Athanasopoulos, G. (2021). Forecasting: Principles and Practice, 3rd edition. OTexts.
3 장 변환, 5 장 기준 예측과 시계열 검증, 7 장 달력·지연 설명변수, 8 장 지수평활.
3 장 · 5 장 · 7 장 · 8 장