학습 전략보고서

2026 AI 농산물 가격예측 온라인 해커톤 본선

팀 정보

IMPACT Lab · 작성자 IMPACT LAB · 작성일 2026-11-08 · 문서 버전 1.2

최종 제출 묶음은 v11_zero_linux 이며 내부 모델 버전은 hackathon-ensemble-v11-zero 입니다. 이 보고서는 아래 세 최고 기록 제출본을 설명합니다. 공통 학습 코드·데이터·실행 환경은 한 번만 기술하고, 트랙별 목표·모델·후처리 차이는 각 규칙 표에서 구분합니다. 아래 ID 표는 「모델별 학습 방법」 표의 세 행에 대응하며, 공통 데이터·검증·재학습 절차는 공통 절에서 설명합니다.

모델	제출 ID · 포털 MAPE	어떤 모델인가요
10 일 예측	efb84521-3be6-400d-a7cd-3bafe184d8b8 9.1231%	hackathon-ensemble-v11-zero 10 일 예측(short). 품목별 고정 규칙의 ExtraTrees/HGB 풀링 은행. 입력: aT 일별가격, 정산물량, 산지·가락·전국 정산 가격, 기상, 공휴일 달력
2 순 후	8a444125-5fa9-4f0b-a629-0798d3ee5e70 11.4627%	같은 묶음의 2 순 후(long1). 2 순 후 10 일 블록 평균가격 예측. 입력 동일
3 순 후	89502728-5402-4953-bc33-87d0f19ca58e 10.8410%	같은 묶음의 3 순 후(long2). 3 순 후 10 일 블록 평균가격 예측. 입력 동일

어떤 데이터를 학습에 사용했나요

학습 자료. 전체 학습 데이터 ZIP(세 트랙 공통, SHA-256 0bac3ca6…)의 운영진 배포 2020~2024 자료를 사용합니다. 가격 자료의 관측 기간은 2020-01-02~2024-12-31, 기상 자료는 2020-01-01 부터이며 대상은 배추·무·양파·깐마늘·건고추입니다. train.py 와 검증 스크립트는 추론 입력을 불러오지 않는 경로를 사용합니다.

자료	파일(training/2020-2024/)	단위·내용	실제 사용
aT 공식 일별 가격	가격_일별_2020_2024.csv (7,040 행, SHA-256 b6ee8aa5…)	unit 열 그대로(10kg·20kg·1kg·600g), 원	학습 목표·기준 수준·가격 특성, 2020-01-02~2024-12-31
전국 도매시장 정산물량	Supplementary/물량_일별_2020_2024.csv (c07f1abc…)	kg	물량 비율 특성
기상청 ASOS 일별 관측	Supplementary/날씨와공휴일_2020_2024/weather_daily.csv (13f4e8a8…)	℃, mm	전국 평균·산지 관측소 기온·강수 창
공휴일 달력	Supplementary/날씨와공휴일_2020_2024/public_holidays.csv (6164030a…, 92 행)	달력	설날·추석 날짜(명절 규칙 잔차 계산)
농협 산지공판장	Supplementary/시장별_경락정보_2020_2024/origin_daily.csv (a8c3a9f2…)	상등급 원/kg, 반입량 t	산지 가격·반입량 특성
가락시장 정산	Supplementary/시장별_경락정보_2020_2024/garak_daily.csv (ae204489…)	정산금액÷정산물량 원/kg, kg	가락 가격·물량 특성
전국 도매시장 정산	Supplementary/시장별_경락정보_2020_2024/wholesale_daily.csv (4a5dfd83…)	원/kg, kg	전국 정산 가격·물량 특성

같은 폴더의 kamis_daily.csv 는 읽지 않습니다. 선택 자료·사전학습 모델·운영진 배포본 이외의 외부자료는 사용하지 않았습니다. 가공 코드는 model.zip 의 data.py, harness.py, extra_features2.py, extra_features3.py, train.py 에 있습니다.

데이터를 어떻게 준비했나요

결측·이상값·단위. 가격은 0 이하·결측을 제외하고 날짜×품목 표로 만듭니다(중복은 마지막 행). 가격을 보간하지 않고 관측값으로 구간 평균을 계산합니다. 수치 정리는 자료별로 다릅니다. 기상은 음수 기온을 유지하며 누락 강수량을 0 으로 채웁니다. 산지 가격은 양수 행, 가락 정산 가격은 정산금액/물량 계산 후 유효 양수 행을 사용합니다. 원 가격 단위를 유지하고, 산지·가락 원/kg 가격의 비율 특성에는 UNIT_KG(배추 10, 무 20, 양파 1, 깐마늘 1, 건고추 0.6)를 적용합니다.

특성 생성. 최종 학습 기준일 후보는 2020-07-01~2024-12-30 의 일별 격자입니다. D 이전 마지막 가격 L, EWMA(e20·e50), 이동평균·수익률·변동성, 연중 일자, 역사적 평균 로그 변화 seas 와 중앙값 seas_med, 전년 동기·시장 간 가격과 물량 비율, 기온·강수와 산지 기상 특성, 예측 거리·구간 길이·블록 모멘텀을 계산합니다. 최근 창과 과거 연도 창의 관측은 모두 D 이전입니다. 기본 y=log(목표가격/L)이며 학습 시 EWMA 기준 수준을 차감합니다. 10 일은 h=1~10 의 일별 가격, 장기는 공식 순 구간의 관측 가격 평균을 목표로 합니다.

학습 변환과 고정 설정. ExtraTrees 의 SimpleImputer 중앙값은 학습 행에 적합해 weights.joblib 에 저장하고 추론에 적용합니다. HGB 는 별도 imputer 없이 결측을 처리합니다. 학습 유효값이 2 개 미만인 열은 0 으로 바꾸며 그 목록을 예측에도 적용합니다. 별도의 표준화 변환은 없습니다. config.json 의 고정 배율·명절 배율과 2022~2024 폴드 잔차 수치의 관계는 아래 계산식 및 검증 JSON 으로 확인합니다.

어떻게 검증하고 모델을 선택했나요

검증 설계. 2020~2024 자료 안에서 2022·2023·2024 년을 차례로 평가하는 연도별 확장 창을 사용합니다. 각 기본 모델은 평가 연도 이전에 종료된 목표만으로 학습하고 그 연도 동안 고정합니다. 예측 기준일이 바뀔 때 입력 특성은 그 기준일 이전 관측으로 다시 계산합니다. 따라서 2022·2023·2024 년은 각각 다음 연도 예측 능력을 점검하는 평가 구간이며, 해당 평가 연도의 정답을 같은 폴드의 기본 모델 학습에 넣지 않습니다[9, 5 장].

평가 연도	기본 모델 학습 자료와 목표 종료 상한	해당 연도 평가 방식
2022	2020~2021 자료 목표 종료일 ≤ 2021-12-31	2022 년 기준일에서 예측 학습한 기본 은행은 해당 연도 동안 고정
2023	2020~2022 자료 목표 종료일 ≤ 2022-12-31	2023 년 기준일에서 예측 학습한 기본 은행은 해당 연도 동안 고정
2024	2020~2023 자료 목표 종료일 ≤ 2023-12-31	2024 년 기준일에서 예측 모든 평가 목표 종료일 ≤ 2024-12-31

표본과 시간 경계. 진단의 학습·평가 사례 표는 2020-07-10 부터 2024-12-30 까지의 10 일 간격 기준일에, 2021~2024 설날·추석 휴장 시작 35 일 전부터 종료 5 일 후까지의 2 일 간격 기준일을 합쳐 구성합니다. 유효한 특성·정답이 있는 행을 사용하며 모든 평가 목표는 2024-12-31 까지 종료됩니다. 모든 일별 기준일을 평가한 것은 아닙니다. 각 학습 행은 목표 구간 전체가 폴드 컷오프 안에 있어야 하고 중심 목표가 있는 경우 추가 관측일까지 검사합니다. 결측 대체 통계도 각 폴드 학습 행에만 적합합니다.

지표와 표 읽는 법. MAPE 는 유효 예측 행의 100×|예측−실제|/실제를 평균합니다. 아래 품목별 점수는 2022~2024 의 평가 행을 합쳐 계산하며 연도별 MAPE 의 단순 평균은 아닙니다. block 은 같은 평가 행의 최근 구간 평균 기준 예측이고, block MAPE−모델 MAPE 가 양수이면 모델의 오차가 더 작습니다. 아래 표에는 고정 배율·감쇠·앵커가 반영되며 명절별 추가 배율은 뒤의 명절 부분집합 진단에서 별도로 평가합니다. 10 일은 거리별 가격, 장기는 목표 순 구간의 관측 가격 평균을 채점합니다. 표본 수는 JSON 의 n_eval_rows_2022_2024 에서 확인합니다.

모델	품목	고정 방법	2022~2024 전진 검증 MAPE	block MAPE − 모델 MAPE (pt)	배율(shrink)
10 일 예측	배추	et	15.08%	+4.87pt	1.0
10 일 예측	무	6 항 혼합	15.52%	+2.37pt	0.9813
10 일 예측	양파	h1last_et_hg_e20_x3	8.50%	+1.77pt	1.0086
10 일 예측	깐마늘 / 건고추	last	0.53% / 1.03%	+0.43 / +0.61pt	1.0
2 순 후	배추	pooled_mw+ewma+seas	21.21%	+6.37pt	0.9442
2 순 후	무	et_mf3_e20_wx	18.51%	−0.42pt	0.9553
2 순 후	양파	et | et+block | et+ewma+seas	12.34%	−0.39pt	0.9827
2 순 후	깐마늘 / 건고추	last	1.25% / 2.00%	+0.40 / +0.10pt	1.0
3 순 후	배추	pooled_mw+ewma+seas	25.07%	+10.32pt	0.9261
3 순 후	무	et_mf3_e20_wx+ewma50	21.86%	+0.91pt	0.9387
3 순 후	양파	et_clip	14.54%	−1.35pt	0.9773
3 순 후	깐마늘 / 건고추	last	1.59% / 2.48%	+0.40 / +0.21pt	1.0

배율·명절 배율의 수치 관계. r=log(실제/L)−모델 로그 비율로 두면, 장기 배추·무는 round(exp(−var(r)),4), 10 일 무·장기 양파는 round(exp(−0.5×var(r)),4), 10 일 양파는 round(exp(−mean(r)),4), 나머지는 1.0 과 일치합니다. 양파 1.0086 은 고정 상향 배율이며 평균 잔차를 0 으로 만드는 편향 중심화가 아닙니다. 명절 배율은 연도별 명절 구간 평균 로그 잔차의 평균에 대해 단기 exp(0.75×평균), 2 순 설날 무 exp(0.50×평균)을 소수점 4 자리로 반올림한 값과 일치합니다. 해당 명절 부분집합의 조정 전후 MAPE 차이는 각각 설날 배추 7.93pt, 추석 배추 3.83pt, 추석 무 0.81pt, 2 순 설날 무 8.57pt 입니다. 전체 트랙 개선량을 뜻하지 않습니다.

보정과 평가의 구분. 기본 모델의 예측은 평가 연도 이전 자료로 학습한 은행에서 생성합니다. 그 예측의 2022~2024 잔차를 모아 배율 계산식을 확인하고 같은 폴드에서 조정 후 점수를 계산하므로, 조정 후 MAPE 는 독립적인 일반화 추정치가 아닙니다. 명절 평균은 각 연도 구간의 평균 잔차를 다시 평균하며, 명절별 효과가 모든 연도에서 동일하게 개선된다고 해석하지 않습니다. Cawley 와 Talbot[8]은 설정 선택에 사용한 유한 표본에서 성능을 다시 평가할 때 발생할 수 있는 선택 편향을 설명합니다.

진단과 선택 이력의 범위. validate_2020_2024.py 는 고정 설정과 수치 계산식을 평가하며 후보 방법·창·혼합비율·감쇠 강도의 최초 탐색을 재현하지 않습니다. 또한 진단은 모든 폴드에 안정화 OLS 기울기를 쓰고 최종 장기 은행 학습은 중심화 np.polyfit 을 사용하므로, 이 표는 제출 가중치의 직접 재현 점수와 구분합니다. 2 순 무·양파와 3 순 양파는 이 표에서 block 보다 낮은 MAPE 를 보이지 않습니다. 최종 설정의 평가 결과와 최초 선택 과정의 근거를 구분해 기록합니다.

진단과 최종 학습의 차이. 최종 train.py 는 검증 격자와 달리 2020-07-01~2024-12-30 의 일별 기준일 후보로 학습 표를 만듭니다. 은행 A 의 목표 종료 상한은 2024-12-30, B 는 2024-12-31 이며 첫 공식 기준일과 이후 기준일에 각각 대응합니다. 2022~2024 관측도 최종 학습에서는 사용 가능한 2020~2024 자료에 포함됩니다. 폴드 모델과 최종 제출 모델의 학습 범위를 이렇게 구분합니다.

시간 순서와 입력 경계. 학습 특성은 각 기준일 이전 관측으로 만들고 목표 종료일이 폴드 또는 은행 컷오프를 넘는 행은 제외합니다. 최종 추론은 input/by_case 의 해당 기준일 이전 관측을 선택하며 모델 가중치와 config.json 의 계수·방법은 고정합니다.

모델	학습 방법과 선택 이유
10 일 예측	5 품목 풀링 ExtraTrees/HGB 은행, 목표 log(가격/L)−EWMA. 품목별 규칙: 배추 et+변동성 감쇠, 무 6 항 로그 혼합+감쇠, 양파 h1last_et_hg_e20_x3, 깐마늘·건고추 last. 명절 배율 설날·추석 적용. 2022~2024 전진 검증으로 수치 확인
2 순 후	같은 은행 학습, 목표는 2 순 후 10 일 블록 평균. 배추 pooled_mw+ewma+seas(×0.9442), 무 et_mf3_e20_wx(×0.9553, 산지 기상 특성), 양파 3 후보 혼합(×0.9827, 변동성 수축 0.25), 깐마늘·건고추 last. 설날 무 블록 배율
3 순 후	목표는 3 순 후 블록 평균. 배추 pooled_mw+ewma+seas(×0.9261), 무 et_mf3_e20_wx+ewma50(×0.9387), 양파 et_clip(×0.9773), 깐마늘·건고추 last. 명절 배율 없음

처음부터 학습하는 방법

최종 학습 설정은 어디에 있나요

설정 위치. 각 모델 ZIP 의 config.json 에 bank_variants, gbm_params, rules, holiday_short·holiday_block 가 있습니다. 세 트랙은 공통 학습 코드와 데이터를 사용하며 package_track 및 트랙 설명·포함 은행을 구분합니다. 최종 학습 기준일 후보는 2020-07-01~2024-12-30(매일), 학습 품목은 5 개, 은행 A·B 목표 컷오프는 각각 2024-12-30·31 입니다.

ExtraTrees. 기본 et 는 그루 수 단기 15/장기 25, max_features=0.5, min_samples_leaf 단기 30/장기 15 입니다. et_mf3 는 특성 비율 0.3, et_hg_x3·et_hg_e20_x3 는 거리 [1,3]/[4,6]/[7,10]별 학습, et_mf3_e20_wx 는 기준 e20 과 wxcr_nov2 특성을 사용합니다. et_clip 은 원 로그 목표를 [−0.6,+0.8]로 자른 뒤 기준 수준을 차감합니다. b1_coint 는 coint 특성·15 그루·특성 비율 0.3 을 사용합니다. 모두 학습 중앙값 imputer 뒤 ExtraTreesRegressor(random_state=0,n_jobs=4)를 적용하며 정확한 변형별 값은 bank_variants 에 있습니다.

HistGradientBoosting. pooled_mw 는 absolute_error, learning_rate=0.03, max_iter=300, max_leaf_nodes=15, l2_regularization=2.0, min_samples_leaf 단기 100/장기 60, random_state=0 입니다. 샘플 가중치는 exp(−y)=L/목표가격입니다. 고정한 scikit-learn 1.9.1 에서 명시하지 않은 조기 종료 설정은 early_stopping="auto", scoring="loss", validation_fraction=0.1, n_iter_no_change=10, tol=1e−7 입니다. auto 는 표본 수가 10,000 을 넘는 경우 등의 라이브러리 조건에 따라 작동합니다. 별도의 사전학습 가중치나 사용자 초기 모델은 사용하지 않습니다.

앙상블·후처리. rules 의 method, shrink, state_space(lam·w_max·target), volshrink 와 명절 설정을 그대로 적용합니다. A|B 는 항별 동일 가중 로그 혼합이며 중복 항은 그만큼 가중됩니다. state_space 는 고정 변동성 감쇠와 가격 공간 앵커 보간의 설정명이며 학습된 Kalman 필터가 아닙니다. 명절의 단기 오프셋은 휴장 구간 경계를 기준으로 합니다. 확률적 추정기에는 random_state=0 을 고정합니다.

주요 설정의 역할과 연구 근거

공통 구조와 학습 용량. 품목별 원 가격을 그대로 한 척도로 섞기보다 log(Y/L)와 품목 정보를 함께 사용해 공통 은행을 적합합니다. 이는 글로벌 시계열 예측의 표본 공유 관점[3]과 로그 변환의 해석[9]에 부합합니다. ExtraTrees 의 무작위 분할[1]과 순차적 트리 부스팅[2]은 서로 다른 예측 구조를 제공합니다. ET 의 기본 15/25 그루, 특성 비율 0.3/0.5, 최소 잎 30/15 와 HGB 의 학습률 0.03·최대 15 잎·L2=2.0·최소 잎 100/60 은 계산량, 분할 세밀함, 갱신 크기를 정하는 고정 설정입니다. 논문은 모델 원리를 설명하고 정확한 값은 config.json 이 정의합니다.

상대오차와 품목 배율. MAPE 가 목표 가격의 역수에 따른 절대오차 가중과 연결된다는 결과[4]를 참고하면 작은 실제 가격의 오차에 더 큰 비중을 주는 목적을 설명할 수 있습니다. 본 HGB 의 L/Y 가중 로그 손실은 이 관점을 적용한 대리 목적함수입니다. Gneiting[7]은 손실함수에 따라 적절한 점예측이 달라짐을 설명합니다. 본 배율은 앞의 잔차 계산식으로 확인하며 로그정규성이나 MAPE 최적성을 가정하지 않습니다. 양파 1.0086 은 고정 상향 배율이며 평균 잔차 중심화라는 명칭을 사용하지 않습니다.

예측 결합과 단순 앵커. [5]의 예측 결합 관점에서 트리·EWMA·block·계절 변화를 함께 사용합니다. 단기 무의 여섯 로그 항에서 b1_coint 는 두 번 들어가므로 외부 혼합 비중은 2/6 이고 나머지 네 항은 각각 1/6 입니다. 단기 앵커 비중은 w=0.25×h/10 으로 거리에 따라 커지며, 깐마늘·건고추에는 last 기준을 유지합니다. EWMA 와 마지막 가격 유지의 근거는 [9, 5·8 장]입니다. 이 문헌이 개별 혼합비율을 지정하는 것은 아니며, 실제 비율은 고정 규칙으로 명시합니다.

거리와 입력 창. [6]은 예측 거리에 따른 편향·분산 문제를 다루며, 본 모델의 1~3 일·4~6 일·7~10 일 묶음은 거리 차이를 표현하면서 그룹 내 표본을 공유하는 구조입니다. 이동 수준·모멘텀·변동성은 짧은 기간과 긴 기간의 상태를 함께 요약합니다. sin/cos 계절성, 명절 달력과 과거 기상·반입량·시장 가격은 설명변수와 지연 정보의 활용[9, 7 장]에 해당합니다. 기상·물량은 실제 관측 시점을 기준일 이전으로 제한하고, 입력 창이나 명절 구간의 개별 최적성을 문헌만으로 주장하지 않습니다.

감쇠와 명절 조정. 단기 변동성 감쇠는 lam×vol30²×h/10(배추 lam=0.10, 무 lam=0.75), 2 순 양파는 0.25×vol30²×h 를 로그 예측에서 차감합니다. 장기 양파의 목표 클리핑과 함께 극단적 변화를 제한하는 고정 규칙이며, 학습된 Kalman 필터로 해석하지 않습니다. 명절 보정은 알려진 이동 명절을 별도로 표현한다는 달력 예측 관점[9]에 연결됩니다. 설날·추석별 창, 0.75/0.50 적용 강도, 배율은 구현 및 폴드 잔차 진단으로 설명하고 문헌에서 도출된 상수로 제시하지 않습니다.

문헌과 실험 근거의 연결. [1]~[7]과 [9]는 최종 구조를 설명하는 방법론적 근거이며 [8]은 검증 결과를 해석하는 근거입니다. 아래 참고문헌은 보고서에서 설계의 의미를 설명하기 위해 연결한 자료입니다. 수치 설정의 확인은 config.json, 고정 설정의 평가 및 배율 계산 확인은 validation_2020_2024.json 과 validate_2020_2024.py, 실행 재현은 reproducibility.json 과 REPRODUCE.md 에 대응합니다.

어떻게 처음부터 학습하나요

세 ZIP 을 model/, training/, input/에 풀고 상위 폴더에서 다음을 차례로 실행합니다(REPRODUCE.md 와 같음).

① 원본 준비: 전체 학습 데이터.zip → training/2020-2024/ (가공 없음, 해시는 training/manifest.json).

② 가공·학습·새 가중치 저장: python model/train.py --out retrained.joblib (2020~2024 만 읽어 특성 표를 만들고 세 트랙의 은행을 모두 학습해 저장, 약 2~3 분)

③ 새 가중치로 예측: python model/predict.py --track short --weights retrained.joblib --output retrained.csv (long1·long2 는 --track 만 변경, 입력은 input/cases.json 과 by_case 폴더)

④ 제출 형식 가중치: python model/split_slim.py retrained.joblib model/config.json short regenerated_weights.joblib (해당 트랙이 읽는 은행만 남김, 예측값 불변)

⑤ 2020~2024 검증 재계산: python model/validate_2020_2024.py (validation_2020_2024.json 과 비교)

기존 weights.joblib 을 읽기만 하는 명령은 script.py / predict.py(--weights 미지정)이며 학습 명령이 아닙니다.

실제로 확인한 결과는 무엇인가요

2020~2024 진단 결과. 앞 표는 제출 ZIP 에 포함된 validation_2020_2024.json 의 수치입니다. validate_2020_2024.py 는 지정된 자료로 이를 새로 계산하고 기존 JSON 과 비교하도록 구현되어

있습니다. 이 문서는 저장된 수치와 스크립트의 계산 범위를 기재합니다. 검증 기준일 격자·표본 수·조정 후 점수의 한계는 앞 절을 참조합니다.

원본 추론 및 재학습 재현. 세 모델의 reproducibility.json/observed_verification 은 2026-11-08 Ubuntu 24.04.4(WSL2, x86_64), CPython 3.14.8 일반 GIL, 지정 패키지, 4 스레드·네트워크 차단 환경에서 저장 가중치 추론과 새 재학습의 결과를 각각 기록합니다. 두 경로 모두 제출 엑셀의 600 개·60 개·60 개 값과 일치하며 최대 차이는 0 입니다.

검증 환경	**모델**	엑셀과 일치	최대 차이	**비고**
Ubuntu 24.04.4 / WSL2 CPython 3.14.8 4 스레드	10 일 예측	600/600	0	저장 가중치 추론·새 Linux 재학습 모두 일치
Ubuntu 24.04.4 / WSL2 CPython 3.14.8 4 스레드	2 순 후	60/60	0	저장 가중치 추론·새 Linux 재학습 모두 일치
Ubuntu 24.04.4 / WSL2 CPython 3.14.8 4 스레드	3 순 후	60/60	0	저장 가중치 추론·새 Linux 재학습 모두 일치

재현 기록의 범위. 같은 Linux 검증 환경의 반복 재학습은 동일한 가중치를 생성했습니다(전체 재학습 출력 SHA-256 f32eb78d…). 최종 후보의 macOS·Windows 재학습은 확인하지 않았습니다. 이전 후보의 타 플랫폼 차이는 이 최종 후보의 확인 결과로 대체 기재하지 않습니다.

재학습할 때 알아야 할 점이 있나요

실행 범위와 주의점. CPU 만 사용하며 학습·추론 중 외부 다운로드는 없습니다. 실행 전 requirements.txt 의 고정 패키지를 준비합니다. script.py/predict.py 는 --output·--audit 경로, train.py 는 --out 경로에 파일을 씁니다. 실행 시간·메모리는 장치와 실행 조건에 따라 달라집니다. 다른 scikit-learn 버전에서는 가중치 로드에 문제가 생길 수 있으며, 다른 플랫폼의 재학습은 일부 예측값이 달라질 수 있습니다. 확인된 재현 범위는 위 Linux 환경입니다.

수치 구현. 최종 장기 은행 학습은 train.LongTrainingFeatureBuilder 의 중심화 np.polyfit 기울기를, 단기 학습과 모든 제출 추론은 harness.py 의 안정화 OLS 기울기를 사용합니다. 두 수식은 수학적으로 같은 기울기를 구하지만 부동소수점 차이가 트리 적합에 영향을 줄 수 있습니다. 따라서 동일성 확인은 실제 검증한 Linux 환경에 한정합니다.

알려진 한계. 조정 배율 산출과 평가에 같은 폴드를 사용했고, 진단과 최종 장기 재학습의 수치 구현도 다릅니다. 검증 표는 독립적인 최종 일반화 성능 보장이나 모든 후보 중 최적 선택의 증명이 아닙니다. 위의 구현·표본·설정·재현 기록을 구분하여 보고합니다.

자동 명세와 증거 위치

파일·SHA-256·라이브러리·은행 및 사례 대응은 reproducibility.json, 실행 명령은 REPRODUCE.md, 고정 설정은 config.json, 진단 수치와 계산 코드는 validation_2020_2024.json 및 validate_2020_2024.py 를 참조합니다.

최종 입력은 input-manifest.json 과 by_case 폴더로 구성되며, 원본 자료의 출처·판본은 학습 자료와 입력 자료의 메타데이터에 보존되어 있습니다. 이 문서는 최종 v11_zero_linux 의 세 제출 ID 와 위 파일을 연결합니다.

확인 범위: 최종 학습 자료·코드·설정·시드와 재학습 명령을 명시하고, 저장된 진단 수치와 기록된 Linux 재현 결과를 구분해 기재했습니다. 미확인 선택 이력 및 타 플랫폼 재학습은 확인된 것으로 표현하지 않았습니다.

외부자료 사용 내역

출처와 판본. 공식 원본의 출처·판본 설명은 학습 ZIP 의 README·TRAINING_MANIFEST·DATA_DICTIONARY 와 입력 ZIP 의 source_metadata 에 보존했습니다. 사례별 잘린 입력의 행 수·관측기간·해시는 input-manifest.json 을 참조합니다. 아래의 원본 해시는 잘린 사례별 파일 해시와 구분합니다.

자료명	공식 출처·파일 위치	공표 시점·근거	사용 항목·기간	학습·추론 용도	미확인 사항
aT 공식 일별 가격 가격_일별_2020_2024.csv / 가격_일별_2025.csv (예측 목표와 같은 가격)	**운영진 배포 학습·입력 자료.** 전체 학습 데이터.zip/2020-2024/가격_일별_2020_2024.csv (SHA-256 b6ee8aa5…), 입력 자료.zip 2025 파일(원본 SHA-256 4796d7c7…)	운영진 배포본의 TRAINING_MANIFEST·DATA_DICTIONARY 기재. 별도 공표 시점 확인은 하지 않음	배추·무·양파·깐마늘·건고추 5 품목. 학습 2020-01-02~2024-12-31, 추론은 각 기준일 D 이전 행만	학습(은행 학습·검증) 및 추론(마지막 가격 L, EWMA 기준 수준, 이동평균·변동성·계절 특징). 12 개 기준일 2024-12-31~2025-11-30	없음
전국 도매시장 정산물량 물량_일별_2020_2024.csv / 물량_일별_2025.csv	운영진 배포 Supplementary. SHA-256 c07f1abc…(2020~2024) / 17a06f91…(2025), 출처 at.agromarket.kr/domeinfo/statsDay.do	운영진 배포본 매니페스트 기재(정산 집계, 공표·수집일은 관측일과 다를 수 있음)	5 품목 kg. 학습 2020~2024, 추론은 D 이전 행만	학습·추론 공통. 물량 비율 특징(v7_30, v7_ly, v30_ly, v14_ly 등)	없음
기상청 ASOS 일별 관측 weather_daily.csv (2020~2024 / 2025)	운영진 배포 Supplementary/날씨와공휴일_*. SHA-256 13f4e8a8…(2020~2024) / fa663b5b…(2025 원본), 출처 data.go.kr/data/15059093	운영진 배포본 DATA_DICTIONARY 기재(관측일 필터만 적용)	전국 관측소 평균 기온(avgTa·minTa·maxTa)·강수량(sumRn)과 일부 산지 관측소. 학습 2020-01-01~2024-12-31, 추론은 tm < D	학습·추론 공통. 14·30 일 기온·강수 창, 서리·폭염·호우 일수(ta14, tmin14, rn14, rn30, n_frost14, n_heat14, n_heavy14)	없음
공휴일 달력 public_holidays.csv (2020~2024 92 행 / 2025 20 행)	운영진 배포 Supplementary/날씨와공휴일_*. SHA-256 6164030a…(2020~2024) / 17c9d363…(2025 원본), 출처 data.go.kr/data/15012690	법정 공휴일 달력(관측값이 아닌 사전 확정 달력 입력)	설날·추석 날짜만 사용. 학습 2020~2024 폴드 잔차 계산, 추론 2025 명절 전후 배율 적용	명절 보정 규칙(config.json holiday_short / holiday_block). 기준일 이후의 명절 날짜도 달력으로 사용	최종 입력 ZIP 의 사례별 2025 달력은 각각 20 행이며 운영진 원본 SHA-256 17c9d363…과 일치합니다. 추가된 2026 년 공휴일 행은 없습니다.

자료명	공식 출처·파일 위치	공표 시점·근거	사용 항목·기간	학습·추론 용도	미확인 사항
농협 산지공판장 가격·반입량 origin_daily.csv / origin_daily_2025_grade12.csv	운영진 배포 Supplementary/시장별_경락정보_*. SHA-256 a8c3a9f2…(2020~2024) / 7c612451…(2025 원본), 출처 nongnet.or.kr 공판장 정보	운영진 배포본 매니페스트 기재	상등급 원/kg 가격·반입량 t. 학습 2020~2024, 추론은 D 이전 행만(품목 단위 환산 UNIT_KG 적용)	학습·추론 공통. 산지 가격·반입량 비율 특징(op7_30, op7_L, oa7_30, oa7_ly)	없음
가락시장 정산 가격·물량 garak_daily.csv / settlement_daily_2025.csv(market_scope=garak)	운영진 배포 Supplementary/시장별_경락정보_*. SHA-256 ae204489…(2020~2024) / 47e4682a…(2025 원본), 출처 at.agromarket.kr/domeinfo/statsDay.do	운영진 배포본 매니페스트 기재(정산 집계)	전체 등급 정산금액÷정산물량 원/kg, 정산물량 kg. 학습 2020~2024, 추론은 D 이전 행만	학습·추론 공통. 가락 가격·물량 비율 특징(gp3_7, gp7_L, gv7_30, gv7_ly)	없음
전국 도매시장 정산 가격·물량 wholesale_daily.csv / settlement_daily_2025.csv(market_scope=national_wholesale)	운영진 배포 Supplementary/시장별_경락정보_*. SHA-256 4a5dfd83…(2020~2024), 출처 at.agromarket.kr/domeinfo/statsDay.do	운영진 배포본 매니페스트 기재(정산 집계)	전국 정산 원/kg·kg. 학습 2020~2024, 추론은 D 이전 행만	학습·추론 공통. 전국 정산 가격·물량 특징(np3_7, np7_30, nv7_30, nv7_ly, nup7)	없음

참고문헌

본문의 [1]~[9]는 아래 문헌에 대응합니다. 논문 8 편과 예측 방법론 교재 1 권을 인용하며, 링크는 출판사 DOI 또는 저자·학술지 공개 원문으로 연결됩니다.

[1] Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. Machine Learning, 63, 3–42.
DOI: 10.1007/s10994-006-6226-1

[2] Friedman, J. H. (2001). Greedy Function Approximation: A Gradient Boosting Machine. The Annals of Statistics, 29(5), 1189–1232.
DOI: 10.1214/aos/1013203451

[3] Montero-Manso, P., & Hyndman, R. J. (2021). Principles and algorithms for forecasting groups of time series: Locality and globality. International Journal of Forecasting, 37(4), 1632–1653.
저자 공개본: arXiv:2008.00444

[4] de Myttenaere, A., Golden, B., Le Grand, B., & Rossi, F. (2016). Mean Absolute Percentage Error for regression models. Neurocomputing, 192, 38–48.
저자 공개본: arXiv:1605.02541

[5] Wang, X., Hyndman, R. J., Li, F., & Kang, Y. (2023). Forecast combinations: An over 50-year review. International Journal of Forecasting, 39(4), 1518–1547.
DOI: 10.1016/j.ijforecast.2022.11.005 · 저자 공개본

[6] Ben Taieb, S., & Hyndman, R. J. (2014). Boosting multi-step autoregressive forecasts. Proceedings of the 31st International Conference on Machine Learning, PMLR 32(1), 109–117.
논문 및 원문: proceedings.mlr.press/v32/taieb14.html

[7] Gneiting, T. (2011). Making and Evaluating Point Forecasts. Journal of the American Statistical Association, 106(494), 746–762.
DOI: 10.1198/jasa.2011.r10138 · 저자 공개본

[8] Cawley, G. C., & Talbot, N. L. C. (2010). On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation. Journal of Machine Learning Research, 11, 2079–2107.
논문 및 원문: jmlr.org/papers/v11/cawley10a.html

[9] Hyndman, R. J., & Athanasopoulos, G. (2021). Forecasting: Principles and Practice, 3rd edition. OTexts.
3 장 변환, 5 장 기준 예측과 시계열 검증, 7 장 달력·지연 설명변수, 8 장 지수평활.
3 장 · 5 장 · 7 장 · 8 장